

PaddleOCR-VL-1.6：通过次优化区域精化与渐进式后训练拓展文档解析的前沿

张泽伦、刘宏恩、梁素音、张宇博、向一清、刘家轩、孙婷、林曼辉、张悦
、周长达、高廷全、崔成[†]、刘毅、于电海、马艳军

PaddlePaddle团队，百度公司

[†] 项目负责人

 官方网站: <https://www.paddleocr.com>

 源代码: <https://github.com/PaddlePaddle/PaddleOCR>

 模型: <https://huggingface.co/PaddlePaddle>

摘要

我们推出 PaddleOCR-VL-1.6，这是一个基于 PaddleOCR-VL-1.5 构建的升级版紧凑型文档解析模型。尽管 PaddleOCR-VL-1.5 建立了 0.9B 的强劲基线，但其剩余错误主要集中在优化不足的区域——这些区域存在模型行为不稳定、数据覆盖稀疏或监督信号不可靠等问题。PaddleOCR-VL-1.6 并未盲目扩充训练语料库，而是引入了区域感知数据优化框架：该框架能识别前一版本模型中的薄弱区域，针对这些区域进行有针对性的增强，并提升监督信号的可靠性。此外，它还采用基于精心筛选的数据选择和强化学习的渐进式后训练方案，通过分阶段优化将模型性能提升至更高水平。PaddleOCR-VL-1.6 在 OmniDocBench v1.6 数据集上取得了 96.33% 的最新最先进成绩，展现出与顶级视觉语言模型（VLMs）抗衡的强劲竞争力，并为 PaddleOCR-VL 系列提供了实用的后训练方案。




图 1 | PaddleOCR-VL-1.6 在 OmniDocBench v1.6 和 Real5-OmniDocBench 上的性能表现。

目录

1 引言	3
2 PaddleOCR-VL-1.6 概述	4
3 基于未优化区域驱动的数据引擎	6
3.1 动机：从均匀缩放到次优化区域优化.....	6
3.2 边界脆弱区域	7
3.3 覆盖稀疏区域	8
3.4 监督不可靠区域	9
3.5 基于多专家共识和渲染引导精化的自动标注	10
4 渐进式后训练方案	11
4.1 用于分布扩展的持续预训练.....	11
4.2 针对困难案例精化的监督微调.....	12
4.3 用于高潜力优化的强化学习	12
5 评估	15
5.1 文档解析	16
5.2 核心子能力.....	18
5.3 消融研究.....	20
6 结论	20

1. 引言

文档解析已成为非结构化文档与大型语言模型应用之间的核心接口。现代文档系统不仅需要提取纯文本，还需识别版面区域、阅读顺序、数学公式、表格、图表、印章以及具有空间定位的文本实例。这种结构化转换决定了文档集合能否被忠实地转换为 Markdown、JSON 或其他机器可读格式，以供下游的索引、检索和推理使用。随着检索增强生成系统越来越依赖高保真度的文档摄取[1]，文档解析已从狭义的OCR任务转向更广泛的视觉-语言问题，该问题需要在异构文档元素之间实现视觉定位、结构重建和语义保留[2, 3, 4, 5]。

近期文档解析领域的进展，既得益于专门的文档视觉语言模型（VLM），也得益于通用多模态模型。PaddleOCR-VL [6] 证明，一个仅含 0.9B 参数的紧凑型视觉语言模型，无需依赖更大的参数规模，即可实现强大的多语言文档解析性能。其他系统，包括 DeepSeek-OCR [7]、MonkeyOCR [2]、Dolphin [4] 和 HunyuanOCR [8]，进一步探索了端到端解析、异构提示以及以 OCR 为中心的统一建模。在此基础上，PaddleOCR-VL-1.5 [9] 在保持紧凑的 0.9B 模型规模的同时，通过提升鲁棒性并扩大任务覆盖范围，进一步强化了 PaddleOCR-VL 系列。这些进展为 PaddleOCR-VL-1.6 奠定了坚实的基础：问题已不再是紧凑型文档解析 VLM 是否可行，而是在主架构已进入高性能阶段后，如何进一步优化它们。

在此范畴内，剩余的误差已无法简单地描述为均匀分布的噪声。最近的基准测试报告和模型分析表明，顶尖系统越来越频繁地遇到仅靠增加数据量或模型规模无法完全解决的难点区域 [6, 3, 10]。即使整体训练语料库规模庞大，长尾文档布局、罕见文字、密集公式、复杂表格以及噪声监督数据仍可能存在表征不足或可靠性不足的问题。PaddleOCR-VL-1.5 [9] 已融入了不确定性感知采样和以失真为导向的鲁棒性改进，这有助于彰显针对性数据构建的价值。PaddleOCR-VL-1.6 进一步拓展了这一方向，将剩余问题视为“优化不足区域”问题：即数据和监督空间中局部区域，模型在这些区域内表现不稳定、覆盖不足，或基于可能不可靠的标签进行训练。

为解决这一问题，我们引入了基于“优化不足区域”的数据引擎。该引擎以 PaddleOCR-VL-1.5 为基础，诊断出三类互补的残余区域。边界脆弱区域包含在不同训练检查点之间或经语义保留的视觉扰动后预测结果发生变化的样本，这表明决策边界不稳定。覆盖稀疏区域对应于特征语义空间中的低密度邻域，在常规采样下，长尾文档模式很可能被主导分布所吸收。外部支持不足区域识别出现有训练样本中那些标签无法得到独立专家解析器支持的情况，这揭示了不可靠的监督而非仅仅是难以处理的输入。随后，这些信号通过两条路径进行处理。边界脆弱和覆盖稀疏的样本作为种子，用于从内部大型文档池中进行区域引导式检索，从而在尽可能少地干扰现有数据分布的情况下，强化这些代表性不足的分布。外部支持不足的样本则用于现有标签的修正。检索到的无标签样本通过专家共识进行标注，未解决的数据则采用“可迭代判断与

精炼”标注策略进行进一步处理。

该引擎生成的精选数据被用于渐进式的后训练流程，而非单一的混合训练阶段。持续预训练阶段整合所有精选数据，向模型注入广泛的分布覆盖范围和经过校正的监督信息。随后，监督式微调阶段专注于高难度、高质量的样本，在 PaddleOCR-VL-1.5 仍表现脆弱或此前基于不可靠标签进行学习的区域内，优化模型行为。最后，应用 GRPO [11] 进一步提升模型性能。由于数据效率对紧凑型模型的强化学习至关重要，我们采用了一种精心设计的、以 GRPO 为导向的数据选择策略。具体而言，从三个维度对候选样本进行综合评估：改进潜力、基于熵的不确定性以及滚动奖励分布。仅选择预期收益最大、价值最高的样本进入最终的强化学习阶段。

PaddleOCR-VL-1.6 通过提供高性能、资源高效的多模态文档解析解决方案，积极应对当前文档处理中的挑战。其主要贡献包括：

- 我们推出 PaddleOCR-VL-1.6，这是基于改进的数据策略和优化后的训练后处理管道构建的 PaddleOCR-VL-1.5 [9] 的升级版本。它在保持高效紧凑的 0.9B 模型规模的同时，在 OmniDocBench v1.6 上实现了最先进性能。
- 我们提出了“欠优化区域挖掘”方法，该方法可诊断模型特有的边界脆弱、覆盖稀疏及监督不可靠区域。我们进一步开发了一条高精度自动标注管道，该管道结合了多专家共识与“可迭代判断与精炼”标注策略，从而实现了未标注样本的大规模标注。
- 针对紧凑型模型的强化学习，我们设计了一种可靠的数据选择策略，因为在该场景下数据质量尤为关键。候选样本从三个互补的角度进行评估：改进潜力、基于熵的不确定性以及滚动奖励分布，从而确保紧凑型模型能够进行有效的强化学习。
- 我们为 PaddleOCR-VL 系列开发了一套渐进式的 CPT-SFT-RL 后训练方案，为高效适应下游特定领域场景提供了切实可行的参考。

2. PaddleOCR-VL-1.6 概述

PaddleOCR-VL-1.6 延续了 PaddleOCR-VL 系列的紧凑设计理念。整个系统由两个模型组成：用于版式分析的 PP-DocLayoutV3 和用于视觉语言理解的 PaddleOCR-VL-1.6-0.9B。在本次升级中，我们保持 PP-DocLayoutV3 不变，重点改进 PaddleOCR-VL-1.6-0.9B 模型。

PaddleOCR-VL-1.6-0.9B 继承了 PaddleOCR-VL-1.5-0.9B [6] 的轻量级架构，集成了原生分辨率视觉编码器 [12]、自适应多层感知机（MLP）连接器以及轻量级 ERNIE-4.5-0.3B 语言模型 [13]。此次升级的主要亮点不在于扩大模型规模或修改架构，而在于采用了更具针对性的数据引擎和经过优化的后训练流程。这种设计使 PaddleOCR-VL-1.6 在保持 PaddleOCR-VL-1.5 高推理效率的同时，实现了更强的系统性能。




图 2 | PaddleOCR-VL-1.6 架构概览。

与前代产品一致，PaddleOCR-VL-1.6 支持两大主要实际任务：文档解析和文本定位。在文档解析方面，该系统采用稳健的两阶段框架。第一阶段中，PP-DocLayoutV3 执行高精度版式分析并支持多点定位，可在透视失真、页面弯曲或文档版式不规则等复杂的实际场景下实现精确的区域定位。在第二阶段，PaddleOCR-VL-1.6-0.9B 对定位后的区域进行识别，涵盖文本、表格、公式、图表和印章等多种文档元素。随后，一个轻量级的后处理引擎将这些输出组织成 Markdown 和 JSON 等结构化格式，并额外支持跨页表格合并和标题层次结构优化。

在文本定位方面，PaddleOCR-VL-1.6 直接采用 PaddleOCR-VL-1.6-0.9B 进行端到端的文本检测与识别。这一简化的工作流支持广泛的应用场景，包括标准文档、身份证件、古籍手稿、广告海报、对话截图、招牌以及多语言文本图像。

与前一版本的主要区别在于 PaddleOCR-VL-1.6 的改进方向。PaddleOCR-VL-1.5 扩展了鲁棒性和任务覆盖范围，而 PaddleOCR-VL-1.6 则专注于解决这一强大基线模型之后仍存在的残余弱点。其开发过程首先从诊断 PaddleOCR-VL-1.5 中优化不足的区域开始，包括预测不稳定、分布覆盖稀疏以及现有标签不可靠的样本。这些诊断信号被用作数据构建和精炼的指导依据，而非单纯视为孤立的评估失败。如图 2 所示，PaddleOCR-VL-1.6 的升级路径围绕数据工程和训练后处理展开：识别残余薄弱区域，针对这些区域进行有针对性的增强以提升模型性能，并采用分阶段优化方案，该方案与每个数据子集的可靠性和学习价值相匹配。

从宏观层面看，PaddleOCR-VL-1.6 包含三个关键组件。第一个组件是基于优化不足区域驱动的数据引擎。它将边界不稳定和覆盖稀疏的区域作为检索种子，用于获取新的未标注样本，同时利用外部支持不足的区域来检测现有训练集中不可靠的标注。第二个组件是

专家共识标注与精炼。检索到的样本由多位专家解析员进行标注，对于专家共识仍不充分的疑难案例，则通过迭代的“判定与精炼”流程进一步优化。第三个组件是渐进式后训练，该组件遵循完整的 CPT-SFT-RL 管道，并作为 PaddleOCR-VL 系列的实用训练方案。在强化学习阶段之前，我们还开发了一种标准化且可重用的样本选择策略，用于识别适用于强化学习的高价值样本。这些组件将在后续章节中详细介绍。

3. 基于次优化区域的数据引擎

3.1. 动机：从均匀缩放转向未优化区域优化

PaddleOCR-VL-1.6 基于其前身已具备强大基线性能的设定。PaddleOCR-VL-1.5 在保持 PaddleOCR-VL 系列 0.9B 紧凑规模的同时，进一步提升了鲁棒性和任务覆盖范围。在如此高性能的背景下，剩余误差已无法仅用通用文档数据不足来解释。虽然均匀扩大训练语料库仍可能引入有用的变体，但也会将有限的训练资源消耗在模型表现已相当可靠的区域上。对于 PaddleOCR-VL 系列等紧凑型模型而言，这一问题尤为重要，因为其最终性能对数据效率和分布平衡更为敏感。因此，与均匀数据扩展相比，有针对性的数据扩展在训练效率和最终模型性能方面都是更有效的策略。




图 3 | PaddleOCR-VL-1.6 数据引擎概览。

我们对 PaddleOCR-VL-1.5 的分析揭示了三种典型的失败模式。首先，微小的像素级位移或保持语义的视觉畸变会导致模型输出发生显著变化，在某些情况下甚至会导致性能严重退化。此类失败难以仅通过在训练中添加标准数据增强来消除，这表明模型尚未在相应的局部数据区域中学习到稳定的映射关系。其次，部分已出现在训练分布中的样本仍被预测错误，这表明周围分布的表征不足，且仍处于优化不足的状态。第三，模型有时会以高置信度产生稳定但错误的输出，这表明问题不仅在于困难的输入，还在于不可靠的监督信号导致所学习的映射存在偏差。

这些观察结果促使我们从模型导向的角度审视数据优化问题。PaddleOCR-VL-1.6 并未将所有额外数据视为同等重要，而是聚焦于“优化不足区域”（UORs），即数据和监督空间中当前模型尚未建立起从文档图像到结构化输出可靠映射的区域。我们根据上述失败模式，识别出三类 UOR：边界脆弱区域（Boundary-Fragile Regions），即在轻微的语义保留变形下预测结果不稳定的区域；覆盖稀疏区域（Coverage-Sparse Regions），即现有数据未能充分覆盖局部分布的区域；以及不可靠监督区域（Unreliable-Supervision Regions），即模型从不可靠的监督信号中学习的区域。基于这些观察结果，我们构建了一个由“优化不足区域”驱动的数据引擎，用于显式挖掘和优化当前模型的薄弱区域，从而针对 PaddleOCR-VL-1.6 进行有针对性的数据优化，如图 3 所示。

3.2. 边界脆弱区域

边界脆弱区域指模型尚未形成从文档图像到结构化输出之间稳定映射的样本。这些区域会降低最终收敛模型的可靠性：即使在相似的训练设置下，优化轨迹的微小变化也可能导致预测结果出现显著差异，且模型在某些场景下可能表现不稳定。提高此类鲁棒性的常见方法是引入数据增强，以促进输入变化下的预测一致性。然而，在我们的实验中，即使结合了十多种增强操作，也无法完全消除某些样本的不稳定性。这表明问题不仅仅在于缺乏通用增强，而是模型在这些样本所代表的局部分布上仍然存在内在的不稳定性。因此，我们需要一种灵活的策略，以在给定模型的自身架构和数据分布下识别其不稳定区域。

我们提出“边界脆弱区域挖掘”（Boundary-Fragile Region mining）作为一种面向模型的策略，用于定位此类不稳定区域。该方法设计上具有普适性：对于不同的模型架构与训练数据分布组合，它都能识别出当前模型尚未学会鲁棒不变性的区域。具体而言，我们从两个互补的视角评估边界脆弱性。第一种视角考察训练后期检查点间的预测变异性，此时模型的整体性能已基本收敛。第二种视角考察对同一检查点施加语义不变的输入畸变后产生的预测变异性。这两种视角共同捕捉了由模型状态变异和输入外观变异共同引发的不稳定性。

视角 1：检查点级不稳定性。检查点视角基于以下观察：在训练接近尾声时，学习率已降至较低水平，且模型的整体性能已基本稳定。因此，对于学习充分的区域，相邻后期检查点的预测结果应保持一致

。然而，在边界脆弱区域中，

即使检查点之间的差异很小，模型的输出仍可能发生显著变化。基于这一直觉，我们保留了训练计划最后8%阶段的八个检查点，并利用它们的预测差异来衡量检查点层面的边界脆弱性。

视角 2：语义不变扰动敏感性。语义不变扰动视角直接衡量模型是否能够抵御那些不应改变文档语义的微小视觉变化。对于每个检查点，我们对同一输入应用一组轻微扰动，并比较所得的预测结果。这些扰动包括像素偏移、JPEG压缩、噪声、模糊、非均匀缩放以及其他轻量级变换，共计形成16种语义不变的失真类型。如果结构化输出在这些失真下发生显著变化，则该样本表明模型在该局部区域尚未学习到稳定的不变性。

对于 PaddleOCR-VL-1.5-0.9B，我们将该挖掘策略应用于完整的训练数据集。每个样本均在 8 个后期检查点与 16 种语义不变变形的笛卡尔积下进行评估，从而得到每个样本 128 个预测结果。随后，我们将这些预测结果序列化为任务输出，并计算每对预测结果的归一化编辑距离，从而得到

$(128 \times 127)/2 = 8128$ 个成对差异分数。为了聚焦于最显著的变异，同时降低微小格式差异的影响，我们选取最大的 128 个成对

距离，并取其平均值作为“边界脆弱性得分”。在最终筛选中，我们根据该得分经验性地选取排名前1%的样本，并额外纳入那些在128个预测中任一预测出现模型退化的样本。

通过这一双视角挖掘过程，PaddleOCR-VL-1.6 既能从后期检查点的不稳定性中，也能从语义不变的扰动敏感性中识别出边界脆弱区域。这些样本揭示了当前模型仍不可靠的局部分布，并作为后续数据检索和精炼的定向锚点。

3.3. 覆盖稀疏区域

覆盖稀疏区域针对的是另一种失败模式。如上所述，即使训练语料库中已出现类似模式，某些样本仍可能被预测错误。这些失败并不一定由不稳定的决策边界引起；相反，它们往往源于周围分布在现有数据中支持度较低。均匀的数据缩放虽然可能增加总体样本量，但若缺乏识别稀疏邻域的机制，仍可能持续对主导分布进行过度采样，同时导致长尾区域代表性不足。因此，PaddleOCR-VL-1.6 需要一种明确的策略来定位当前训练分布中的覆盖稀疏区域。

PaddleOCR-VL-1.6 通过视觉语义邻域视角来诊断覆盖稀疏性。数据引擎首先使用内部的文档专用特征编码器，为所有训练样本提取表征。随后，它在生成的特征空间中测量样本相似度，并发现那些规模较小、连接性较弱的异常值簇，将其作为“覆盖稀疏区域”的候选。这些簇表明了当前语料库在局部邻域中未能提供充分分布支持的区域。

算法 1 覆盖稀疏区域挖掘

需求：训练样本 $D = \{x_i\}_i^N$ ，文档特定特征编码器 $f(\cdot)$ ，目标聚类数 K_{target} ，初始相似度阈值 τ_0 ，阈值步长 $\Delta\tau$ 。

确保：候选项覆盖范围——稀疏区域 R_{cs} 。

- 1: 对于所有 $x_i \in D$ ，提取归一化文档特征 $z_i = f(x_i)$ 。
 - 2: 计算成对余弦相似度 $s_{ij} = z_i^T z_j$ 。
 - 3: 构建初始相似度图 $G = (V, E)$ ，其中 $V = D$ 且 $E = \{(i, j) \mid s_{ij} \geq \tau_0\}$ 。
 - 4: 从 G 中获取连通分量 C ，并设置 $\tau \leftarrow \tau_0$ 。
 - 5: **只要** $|C| < K_{target}$ ，**就执行以下操作**
 - 6: 更新阈值 $\tau \leftarrow \tau + \Delta\tau$ 。
 - 7: 初始化 $C_{new} \leftarrow \emptyset$ 。
 - 8: **对于每个组件** $C \in C$ ，**执行以下操作**
 - 9: 构造 $G_C = (C, E_C)$ ，其中 $E_C = \{(i, j) \mid x_i, x_j \in C, s_{ij} \geq \tau\}$ 。
 - 10: 将 C 划分为 G_C 的连通分量，并将它们加入到 C_{new} 中。
 - 11: **end for**
 - 12: 更新 $C \leftarrow C_{new}$ 。
 - 13: **结束 while**
 - 14: 从 C 中选取较小的离群分量作为 R_{cs} 。
 - 15: **返回** R_{cs} 。
-

如算法 1 所示，该方法通过逐步提高相似性阈值来揭示细粒度的聚类。它并非一次性将所有样本强行归入固定的划分中，而是逐步拆分相似性图，并识别出局部密度较低的小型离群子成分。

这种以密度为导向的聚类策略非常适合“覆盖稀疏区域”的挖掘。其目标并非获得平衡的语义聚类，而是揭示那些容易被主导分布掩盖、支持度较低的尾部邻域。相比之下，K-Means 等固定 K 聚类方法需要预先指定聚类数量，并将每个样本分配到一个聚类中，这可能会导致罕见文档模式被吸收进附近的密集群组中。通过保持邻域连通性，我们的方法使稀疏区域保持可见，并将其用作有针对性的数据扩展种子。基于挖掘出的“覆盖稀疏区域”，PaddleOCR-VL-1.6 系统性地补充了长尾数据（如古籍、罕见字符和工业表格），进一步提升了模型在代表性不足场景下的表现能力。

3.4. 不可靠监督区域

前两种挖掘策略主要识别需要分布扩展的薄弱区域：边界脆弱区域揭示了局部不稳定的样本，而覆盖稀疏区域则揭示了当前语料库中代表性不足的邻域。在实践中，我们观察到模型可能会反复产生相同的高置信度错误模式，这表明某些失败源于不可靠的监督，而非覆盖不足。因此，“不可靠监督区域”挖掘聚焦于现有标签本身，旨在识别不准确的目标，并提升训练集监督的整体有效性。

为了诊断此类区域，我们引入了一种基于外部支持的验证策略。其核心思想是：基于不同数据源和模型架构训练的高性能模型，可以针对同一样本提供独立的专家观点，从而有助于打破

原始标注系统的偏差。具体而言，我们采用Qianfan-OCR [14]、GLM-OCR [15] 和 MinerU2.5-Pro [16] 作为三个专家模型，每个模型针对同一训练样本分别生成独立的预测结果。随后，根据专家预测的一致性对原始标签进行验证或更正。如果至少有一项专家预测与原始标签一致，则该样本被视为“外部支持”，并保留原始标签；如果原始标签与所有专家预测均不一致，但至少有两项专家预测相互一致，则该样本被视为“可修正标签”，并用专家共识结果替换原始标签。如果原始标签与三位专家均未达成一致，则该样本被标记为“未解决”，并送入下一节所述的后续精细自动标注策略中。

该策略提供了一种保守但有效的方法来修复监督噪声。通过这一过程，PaddleOCR-VL-1.6 挖掘并优化了从 PaddleOCR-VL-1.5 继承而来的“不可靠监督区域”。此外，专家之间的一致性模式自然地数据难度进行了分层：通过专家共识解决的样本可作为高置信度的修正数据，而专家之间未达成一致的样本则被视为难点案例，并在后续的训练后阶段中予以谨慎处理。

3.5. 基于多专家共识和渲染引导精化的自动标注

在完成“优化不足区域”挖掘后，数据引擎会获得两类需要可靠监督的样本。使用“边界脆弱”和“覆盖稀疏”种子从内部文档池中检索到的样本是无标签的。与此同时，从“不可靠监督区域”中识别出的样本可能已有标签，但这些标签缺乏足够的外部支持，因此需要校正或精炼。PaddleOCR-VL-1.6 引入了一条高精度自动标注管道，该管道将多专家共识与渲染引导的迭代精炼相结合。

对于表格识别和公式识别等困难的文档解析任务，标签生成通常需要更强的测试时推理能力，尤其是在多个专家模型产生不一致输出时。因此，作为处理困难案例的“判断与精炼”模型，我们采用了 ERNIE 5.0 [17]——这是一种原生自回归基础模型，专为跨文本、图像、视频和音频的统一多模态理解与生成而设计，并具备强大的视觉推理能力。如算法 2 所示，该流程首先收集来自三个专家模型（PaddleOCR-VL-1.5 [9]、GLM-OCR [15] 和 MinerU2.5-Pro [16]）的预测结果。如果至少有两个专家模型意见一致，则直接采纳其共识输出作为标签；否则，该样本将被视为困难样本，并进入渲染引导的“判定与精炼”阶段。

该设计包含两个实用的细节。首先，三个专家模型的预测结果仅在初始 ERNIE 5.0 [17] 预测阶段被注入。后续的精炼轮次仅使用当前预测结果以及前一轮“判断”步骤中识别出的差异，从而避免重复的专家输出结果对精炼轨迹产生偏倚。其次，“判断”步骤是基于渲染的，而非纯粹基于文本的。对于公式和表格，即使对于强大的多模态模型，直接将图像与 LaTeX 或 HTML 进行比较也较为困难。渲染候选输出可将比较转化为同模态的视觉匹配问题，从而使评审员能够更准确地定位行或列对齐错误、跨单元格错误以及内容放置错误。

算法 2 多专家共识与渲染引导的标签精化

输入：输入图像 x ，专家模型 $\{E_1, E_2, E_3\}$ ，评判与精炼模型 M ，最大精炼轮数 T 。

确保：接受标签 y 或带有预标签 $y^{\wedge}$ 的手动标注请求。

```
1: 使用  $\{E_{(1)}, E_{(2)}, E_{(3)}\}$  生成专家预测  $\{y_1, y_2, y_3\}$ 。
2: 如果 至少有两位专家的预测一致，则
3:   将 $y$  设置为专家共识结果。
4:   返回被接受的标签 $y$ 。
5: end if
6:  $y^{\wedge(0)} \leftarrow M_{\text{精化}}(x, y_1, y_2, y_3)$  {基于专家参考的初始预测}
7: 对于  $t = 0$  到  $T - 1$ ，执行以下操作
8:   将 $y^{\wedge(t)}$  渲染为图像 $r^{(t)}$ 。
9:    $\delta^{(t)} \leftarrow M_{\text{judge}}(x, r^{(t)})$  {检测输入图像与渲染预测结果之间的差异}
10:  如果  $\delta^{(t)} = \emptyset$  则
11:     $y \leftarrow y^{\wedge(t)}$ 
12:    返回已接受的标签 $y$ 
13:  end if
14:   $y^{\wedge(t+1)} \leftarrow M_{\text{refine}}(y^{\wedge(t)}, \delta^{(t)})$  {根据检测到的差异优化预测}
15: 结束 for 循环
16: 返回手动标注请求，并将最后一次预测结果 $y^{\wedge(T)}$  作为预标注。
```

该管道使 PaddleOCR-VL-1.6 能够为大多数困难样本自动生成可靠的标签。未解决的案例将转交人工标注，并使用管道的最终输出作为预标注，以减少人工工作量。

4. 渐进式后训练方案

PaddleOCR-VL-1.6 并非从零开始训练，而是基于 PaddleOCR-VL-1.5 的检查点，通过精心设计的渐进式后训练方案来提升模型性能。当基础架构达到强劲的性能水平后，关键目标在于高效吸收新构建的高价值数据，而非重新启动大规模预训练。本节描述了由“未优化区域驱动数据引擎”生成的数据如何分配到三个阶段。持续预训练（CPT）吸收广泛的精心筛选数据，以扩展分布覆盖范围并整合经过修正的监督信息。监督微调（SFT）专注于高质量的困难样本，以优化文档解析行为。强化学习（RL）则利用可验证的奖励，进一步优化高潜力的样本。这种分阶段设计根据每个数据子集的可靠性和学习价值进行利用，在保持紧凑的 0.9B 模型规模的同时，提升了 PaddleOCR-VL-1.6 的性能。

4.1. 分布扩展的持续预训练

第一阶段旨在吸收新引入的扩展数据分布。除了提高现有标注的可靠性外，数据引擎还从先前优化不足的领域引入了大量新检索的样本，包括古籍、罕见字符以及其他长尾文档场景。这些样本引入了分布偏移，而这种偏移无法通过狭窄的监督式微调阶段完全学习。因此，在进入

进行更具选择性的优化阶段之前，将这些新的文档模式注入并加以稳定。

训练数据。CPT语料库整合了完整的SFT数据和PaddleOCR-VL-1.5的部分预训练数据，以及数据引擎生成的所有新检索数据，总计1680万个训练样本。所有样本均采用最新的标注，既提供了更广泛的覆盖范围，又确保了更高质量的监督。

训练设置。所有模型参数均解冻，以适应扩展后的分布。我们以全局批量大小为1024进行一个epoch的训练，并将最大学习率设置为 3×10^{-5} 。

4.2. 基于监督的微调以优化棘手案例

CPT扩展了模型的分布覆盖范围并建立了其基础能力，而SFT则利用可靠的监督数据，针对困难样本进一步优化模型。此阶段的目标并非均匀地复用所有精心整理的数据，而是将监督学习集中于模型仍需强化任务表现的场景。

训练数据。SFT语料库由三个来源构建而成。首先，我们遵循PaddleOCR-VL-1.5 [18]中使用的“不确定性感知聚类采样”(UACS)策略，从CPT语料库中挖掘困难样本。其次，我们纳入了所有三位专家未能达成一致、因此进入“渲染引导精炼”管道的样本。这些样本在构造上就具有高难度，在获得可靠标签后仍需进一步的监督学习。第三，我们纳入了原本存在于PaddleOCR-VL-1.5训练数据中、但其标签已通过“不可靠监督区域”挖掘被识别并更正的样本。该过程总共为SFT筛选出730万个样本。

训练设置。所有模型参数均未冻结。我们以全局批量大小为1024进行一个epoch的训练，并将所有参数的最大学习率设置为 1×10^{-5} 。

4.3. 基于强化学习的高潜力优化

强化学习(RL)为超越监督学习提供了额外的优化信号。由于训练语料库包含来自不同来源且标注风格各异的大规模数据，模型可能会针对相似的输入模式产生多种输出风格。RL有助于规范这些行为，同时在抑制分布外样本上的退化现象时，进一步提升模型性能和泛化能力。

然而，将强化学习应用于PaddleOCR-VL-1.6-0.9B需要谨慎的数据选择。由于语言模型部分仅为0.3B，这种紧凑型模型对强化学习数据的质量和样本效率更为敏感。如果采用随意策略选择强化学习样本，模型可能会在部分困难案例上有所提升，但整体性能却会下降。因此，强化学习阶段必须聚焦于既可学习、又可能带来有意义的奖励驱动型提升的样本。为解决这一问题，我们提出了一种基于GRPO的高潜力样本挖掘策略，用于筛选有效的强化学习训练样本，从而稳定强化学习训练过程，并确保奖励驱动优化效果。

4.3.1. 基于GRPO的高潜力样本挖掘

GRPO [11] 通过比较同一输入的多个采样响应，并根据组内相对奖励分配优势值来优化策略。这种基于组相对性的公式消除了对独立价值模型的需求，但也使得

训练效果在很大程度上取决于每个提示能否产生具有信息量的奖励差异。对于 PaddleOCR-VL-1.6-0.9B 而言，这一要求尤为重要，因为其语言模型组件较为紧凑，导致策略对噪声、过易、过难或奖励平坦的强化学习样本更为敏感。

因此，我们引入了一种基于 GRPO 的高潜力样本挖掘策略，根据当前的 SFT 策略来选择强化学习数据。将 SFT 模型用作初始策略，以探测候选强化学习数据池。对于每个候选样本 x ，我们生成 16 次滚动，其温度为 0.85， $\text{TOP-}p = 0.9$ ， $\text{TOP-}k = 32$ 。每次滚动均通过下一节所述的任务特定可验证奖励函数进行评估，从而为该样本生成经验奖励分布。

非信息性样本过滤。第一步是剔除那些不太可能为 GRPO 提供有用更新的样本。当最大滚动奖励 $r_{\max}(x)$ 低于阈值时，会过滤掉难度过高的样本，因为当前策略永远无法达到足够输出，且奖励信号主要表明失败。当平均奖励 $r_{\text{mean}}(x)$ 高于阈值时，则过滤掉过于简单的样本。

当平均奖励 $r_{\text{mean}}(x)$ 高于阈值时，这些样本会被过滤，因为模型已经解决了这些样本，且剩余的优化空间很小。我们进一步将样本的学习潜力定义为

$r_{\max}(x) - r_{\text{mean}}(x)$ 。较小的差距表明，即使最佳采样输出也并未在实质上优于平均滚动输出，因此该样本为奖励驱动的学习提供的机会有限

改进。最后，由于 GRPO 依赖于采样组内的相对奖励差异，因此会移除奖励方差极低的样本；奖励平坦的滚动样本会提供微弱或退化的优势信号。

高潜力样本评分。对于剩余的候选样本，我们计算一个统一的高潜力评分，该评分综合考虑了改进空间、生成不确定性和奖励

多样性。主导项是学习潜力差距 $r_{\max}(x) - r_{\text{mean}}(x)$ ，该指标衡量当前策略是否偶尔能产生远优于其平均

表现。我们还通过在

当前策略下采样到的滚动过程的似然函数来估算生成不确定性。对于第 k 个滚动过程 $y^{(k)} = (y^{(k)}_1, \dots, y^{(k)}_{T_k})$ ，我们定义其长度归一化的

序列置信度定义为

$$C_{y^{(k)} | x} = \frac{1}{T_k} \prod_{t=1}^{T_k} p_{\theta}(y^{(k)}_t | x, y^{(k)}_{<t}). \quad (1)$$

该几何平均值消除了原始序列似然值的长度偏差，并衡量了当前策略在令牌层面上生成该滚动结果的置信度。随后，通过求 K 个滚动结果的平均值来计算样本层面的不确定性：

$$U(x) = 1 - \frac{1}{K} \sum_{k=1}^K C_{y^{(k)} | x}, \quad K = 16. \quad (2)$$

更大的 $U(x)$ 表明，当前策略对其在 x 上采样的输出赋予的平均置信度较低，这暗示生成行为尚未稳定，可能仍需通过策略优化来改进。

此外，我们利用奖励方差来衡量采样滚动是否在任务奖励下揭示了有意义的差异：

$$V_r(x) = \frac{1}{K} \sum_{k=1}^K r^{(k)}(x) - r_{\text{均值}}(x)^2, \quad (3)$$

其中 $r^{(k)}(x)$ 是 k 第次滚动 (rollout) 的奖励, $r_{\text{均值}}(x) = \frac{(1)}{K} \sum_{k=1}^K r^{(k)}(x)$ 。而 $U(x)$ 表示生成过程中的不确定性, $V_r(x)$ 则反映了任务层面的结果多样性, 这与群体相对优化直接相关。

最终的高潜力得分定义为

$$\text{Score}(x) = (r_{\text{max}}(x) - r_{\text{mean}}(x)) \cdot \exp(\alpha U(x) + \beta V_r(x)), \quad (4)$$

其中 $r_{\text{max}}(x) = \max_k r^{(k)}(x)$, 而 α 和 β 分别控制发电不确定性和奖励方差的贡献 (实际中我们设定 $\alpha = 1$ 且 $\beta = 2$)。主导项

$r_{\text{max}}(x) - r_{\text{mean}}(x)$ 衡量样本可实现的改进空间, 而

指数因子则会提高那些在当前条件下其展开结果均存在不确定性的样本的权重

在任务奖励下, 策略既具有学习性又具有区分性。这种表述优先考虑的样本不仅具有难度, 而且是可学习的: 策略在某些滚动模拟中已经能够达到更好的解, 奖励分布提供了具有区分性的组间相对信号, 且生成过程仍存在足够的不确定性, 从而能从优化中获益。

为了保持任务平衡, 该评分和筛选过程针对所有任务 (包括 OCR、图表解析、表格识别、公式识别、印章识别和文本定位) 分别进行。随后, 各任务中排名靠前的样本将用于最终的 GRPO 阶段。通过这种方式, 强化学习 (RL) 训练将聚焦于具有可观察改进潜力的高质量候选样本, 而非从整个候选样本池中均匀采样。这稳定了 GRPO 优化过程, 并使奖励驱动的学习对于紧凑型 PaddleOCR-VL-1.6-0.9B 模型更为有效。

4.3.2. 奖励设计

对于 PaddleOCR-VL-1.6-0.9B 这样的紧凑型模型, 过于稀疏的二进制奖励提供的学习信号有限, 导致模型难以有效受益于强化学习。因此, 我们设计了一种基于表示的可验证奖励, 该奖励在提供与任务对齐的标量反馈的同时, 仍能强制执行严格的有效性约束。对于每个任务 t , 模型输出 y

和参考值 y^* 首先通过 φ_t 映射到任务特有的规范表示中。最终奖励定义为

$$R_t(y, y^*) = \text{Valid}_t(y) \cdot \text{Struct}_t(\varphi_t(y)) \cdot \text{Sim}_t(\varphi_t(y), \varphi_t(y^*)), \quad (5)$$

其中, Valid_t 是一个严格的有效性门控, Struct_t 是一个结构调整因子, Sim_t 是任务对齐的相似度度量。有效性门控定义了可用任务输出的最低要求, 且为二进制: 格式无效、LaTeX 语法错误、截断、退化或其他任务特定错误的输出将获得零奖励。结构因子会对可解析但需要后处理修正的输出进行轻微扣分。例如, 非矩形的 OTSL 表格输出将根据将其转换为有效矩形结构所需的最小编辑成本进行扣分。随后, 相似性项使用适合各任务的度量标准, 衡量有效且规范化的输出与参考结果的接近程度。各任务的奖励设计总结如表 1 所示。

具体而言, 对于文本定位任务, 每个几何匹配的预测框-参考框对都会根据文本相似度进行加权, 该相似度采用预测字符串与参考字符串之间的 $1 - \text{NED}$ 值计算。这产生了一个基于编辑相似度加权的 F1 分数, 该分数同时奖励准确的定位和识别提供奖励, 而非将所有匹配的框都视为同样正确。

任务	有效 _{<i>t</i>}	结构 _{<i>t</i>}	相似度Sim _{<i>t</i>}
表	模型退化 输出截断 无法解析的 OTSL 输出	单元级 LaTeX 有效性 OTSL 矩形度成本	TEDS
OCR	模型退化 输出截断	结构 _{<i>t</i>} = 1	1 - NED
公式	无效的内联 LaTeX 模型退化输出截断	结构体 _{<i>t</i>} = 1	CDM
Seal	LaTeX 语法错误 模型退化输出截断	结构 _{<i>t</i>} = 1	1 - NED
图表	模型退化 输出截断无效的 Markdown 表格 行或列格式错误	表格矩形度成本	RMS-F1
定位	模型退化输出截断无效 输出格式	结构 _{<i>t</i>} = 1	编辑相似度加权F1 得分

表 1 | PaddleOCR-VL-1.6 的奖励设计。每个任务均遵循相同的“有效-结构-相似性”框架，同时采用任务特有的有效性检查、结构因子和相似性度量。

4.3.3. 训练数据与设置

训练数据。我们构建了一个经过精心筛选的强化学习候选数据池，该数据池具有统一的标注风格、高质量的参考样本以及能够提供有意义奖励信号的挑战性样本。以SFT模型作为滚动策略，我们应用上述高潜力样本挖掘策略，对该候选数据池中的样本进行探测、过滤和评分。针对每个任务，我们根据最终挖掘分数经验性地选取排名前 8K 的样本用于 GRPO 训练。最终生成的强化学习训练集共计包含 49K 个样本。

训练设置。在强化学习阶段，所有模型参数均保持解冻状态。我们以全局批量大小为 1024 进行两个 epoch 的训练，并将所有参数的最大学习率设置为 2×10^{-6} 。在滚动采样过程中，我们采用温度 0.85、top-*k* 为 32、top-*p* 为 0.9，以及组大小 *G* 为 16。遵循 DAPO [19]，我们采用剪切更高策略，其中 $\epsilon_{\text{high}} = 0.28$ 。我们还使用 DAPO 中的动态采样策略，忽略那些组内奖励方差为零的群组，从而确保 GRPO 更新仅基于具有显著相对奖励差异的样本进行计算。

5. 评估

为了全面评估 PaddleOCR-VL-1.6 的有效性，我们在文档解析基准 OmniDocBench v1.6[16] 和

Real5-OmniDocBench[20] 上进行了评估。此外，我们通过纳入困难表格识别、图表解析、文本定位和印章识别任务来扩展评估范围，从而对模型在实际和复杂场景中的性能进行更全面的分析。

5.1. 文档解析

本节详细介绍了利用以下两个基准测试对端到端文档解析能力的评估，旨在衡量其在真实文档场景中的整体性能。

OmniDocBench v1.6我们还基于 OmniDocBench v1.6 进行了评估，该版本是 OmniDocBench v1.5 的更新版。与 v1.5 相比，v1.6 引入了两项关键改动。首先，它采用了多粒度自适应匹配（MGAM）技术，以减少固定粒度一对一元素匹配所导致的匹配偏差。这提高了在预测结果采用与 ground truth 不同但语义等价的分段时，评估的鲁棒性。其次，它新增了一个包含 296 页的专用“困难子集”，涵盖了更具挑战性的文档解析场景，包括复杂的嵌套表格、密集的公式布局以及非常规的文档结构。因此，OmniDocBench v1.6 提供了更全面的评估。评估指标仍针对具体任务而定。文本和阅读顺序采用基于编辑距离的相似度进行评估，表格采用 TEDS 进行评估，公式则采用 CDM [21] 进行评估。借助 MGAM，这些指标是在一种自适应匹配策略下计算的，该策略可缓解分段粒度不匹配的问题，最终得分是根据被评估的文档元素汇总而成的。

表 2 表明，PaddleOCR-VL-1.6 实现了业界领先的整体性能，始终优于现有的通用 VLM 和专用文档解析模型。值得注意的是，PaddleOCR-VL-1.6 相较于其前身 PaddleOCR-VL-1.5 实现了显著的性能飞跃，将总得分从 94.93% 提升至位居前列的 96.33%。具体而言，它在文本编辑距离、CDM 得分、表格 TEDS 以及表格 TEDS-Structure 方面分别实现了 0.5%、0.6%、3.09% 和 2.74% 的提升。此外，我们的模型在主要解析子任务中创下了新的最先进水平，包括将文本编辑距离缩小至 0.033，公式 CDM 得分提升至 97.49%，并在表格 TEDS 和表格 TEDS-S 任务中分别取得 94.76% 和 97.11% 的领先得分。此外，该模型在阅读顺序（Reading Order）指标上也取得了 0.127 的极具竞争力的分数，与该指标上表现最佳的模型不相上下。这些改进凸显了该模型在文本识别、公式提取和复杂表格结构分析方面的精度提升。

Real5-OmniDocBenchReal5-OmniDocBench [20] 是近期提出的一个基准测试集，旨在评估文档解析模型在真实世界条件下的表现。该测试集基于 OmniDocBench v1.5 构建，涵盖五个代表性场景：扫描、变形、屏幕截图、光照变化和倾斜。除扫描子集外，所有图像均使用手持移动设备手动拍摄，紧密模拟了实际的文档采集场景。每个子集与原始 OmniDocBench 样本保持一对一对应关系，并遵循相同的 ground-truth 标注和评估协议。凭借其实地采集且场景多样化的数据，Real5-OmniDocBench 为评估文档解析模型在实际应用中的鲁棒性提供了一个严谨的测试平台。

如表3所示，PaddleOCR-VL-1.6在Real5-OmniDocBench上取得了最佳的整体性能，以93.19%的总分创下了新的最先进水平。与前代模型 PaddleOCR-VL-1.5 相比，其综合得分提高了 1.14 个百分点，从 92.05% 提升至 93.19%。尽管参数规模仅为 0.9B，PaddleOCR-VL-1.6 的表现仍远超参数规模

大得多的通用大型语言模型（VLMs），包括 Qwen3-VL-235B 和 Gemini-3 Pro，这凸显了其在文档相关任务中出色的参数效率。

模型类型	方法	参数	总体↑	文本 ^{编辑} ↓	公式 ^{CDM} ↑	表格 ^{TEDS} ↑	表格 ^{TEDS-S} ↑	阅读顺序 ^{编辑} ↓
通用VLMs	InternVL3.5-241B [22]	241B	83.76	0.130	89.95	74.35	79.78	0.215
	Kimi K2.5 [23]	1T	84.53	0.107	83.50	80.76	84.00	0.211
	GPT-5.2 [24]	-	86.59	0.114	88.21	82.95	87.93	0.193
	Qwen3-VL-235B [25]	235B	89.78	0.063	92.55	83.07	86.75	0.166
	Gemini 3 Flash [26]	-	92.62	0.066	95.16	89.29	93.51	0.172
	Gemini 3 Pro [26]	-	92.91	0.064	95.99	89.15	92.96	0.165
	Ovis2.6-30B-A3B [27, 28]	30B	93.70	0.035	95.17	89.44	92.40	0.135
专用VLM	POINTS-Reader [5]	3B	83.37	0.096	85.72	73.98	77.40	0.198
	Nanonets-OCR-s [29]	3B	83.61	0.108	81.46	80.18	84.51	0.213
	Mistral OCR [30]	-	85.66	0.097	89.91	76.78	80.93	0.171
	olmOCR [31]	7B	85.74	0.139	88.10	83.00	87.17	0.216
	Dolphin-1.5 [4]	0.3B	86.52	0.094	87.49	81.43	84.82	0.167
	MonkeyOCR-pro-3B [2]	3B	88.57	0.074	88.74	84.35	88.62	0.189
	OCRVerse [32]	4B	88.60	0.063	89.61	82.44	86.27	0.163
	Dolphin-v2 [4]	3B	89.50	0.069	91.01	84.40	87.44	0.150
	HunyuanOCR [8]	1B	89.95	0.088	87.68	91.01	93.23	0.171
	DeepSeek-OCR 2 [7]	3B	90.25	0.050	91.84	83.89	87.75	0.144
	OpenDoc-0.1B [33]	0.1B	90.67	0.049	93.02	83.88	87.45	0.140
	dots.ocr [34]	3B	90.77	0.048	89.95	87.18	90.58	0.138
	MinerU-2.5 [3]	1.2B	93.04	0.045	95.77	87.88	91.47	0.130
	FireRed-OCR [35]	2B	93.26	0.037	95.44	88.04	91.06	0.131
	Logics-Parsing-v2 [36]	4B	93.33	0.041	95.65	88.42	91.98	0.137
	YouTube解析 [37]	25亿	93.74	0.044	93.63	92.02	95.00	0.116
	Qianfan-OCR [14]	4B	93.90	0.040	95.08	90.53	93.31	0.130
	PaddleOCR-VL [6]	0.9B	94.18	0.040	95.91	90.65	93.74	0.135
	PaddleOCR-VL-1.5 [9]	0.9B	94.93	0.038	96.89	91.67	94.37	0.130
	GLM-OCR [15]	0.9B	95.22	0.044	97.18	92.83	95.39	0.133
	MinerU2.5-Pro [16]	1.2B	95.75	0.036	97.45	93.42	95.92	0.120
	PaddleOCR-VL-1.6	0.9B	96.33	0.033	97.49	94.76	97.11	0.127

表 2 | OmniDocBench v1.6 的综合评估。性能指标引用自官方排行榜 [38]。在所有评估模型中，PaddleOCR-VL-1.6 取得了最佳的整体性能

。

模型类型	方法	参数	总体↑	扫描↑	畸变↑	屏幕摄影↑	照明↑	倾斜↑
管道工具	Maker-1.8.2 [39]	-	60.10	70.27	58.98	63.65	66.31	41.27
	PP-StructureV3 [40]	-	64.45	84.68	59.34	66.89	73.38	37.98
通用VLM	GPT-5.2 [24]	-	78.66	84.43	76.26	76.75	80.88	75.00
	Qwen2.5-VL-72B [41]	72B	86.92	86.19	87.77	86.48	87.25	86.90
	Gemini-2.5 Pro [42]	-	88.21	89.25	87.63	87.11	87.97	89.07
	Qwen3-VL-235B-A22B-Instruct [25]	235B	88.904	89.43	89.99	89.27	89.27	86.56
	Gemini-3 Pro [26]	-	89.24	89.47	88.90	88.86	89.53	89.45
专用VLM	Dolphin-1.5 [4]	0.3B	61.48	83.39	50.50	69.76	75.61	28.16
	海豚 [4]	0.3B	61.78	72.16	60.35	64.29	67.29	44.83
	Deepseek-OCR 2 [7]	3B	73.01	89.59	66.53	71.65	76.02	61.28
	Deepseek-OCR [7]	3B	73.99	86.17	67.20	75.31	78.10	63.01
	MinerU2-VLM [43]	0.9B	76.95	83.60	73.73	78.77	80.51	68.16
	MonkeyOCR-pro-1.2B [2]	1.9B	77.15	84.64	76.59	80.24	82.11	62.18
	MonkeyOCR-3B [2]	3.7B	78.29	84.65	77.27	80.71	83.16	65.67
	MonkeyOCR-pro-3B [2]	3.7B	79.49	86.94	78.90	82.44	84.71	64.47
	Nanonets-OCR-s [29]	3B	84.19	85.52	83.56	84.86	85.01	81.98
	PaddleOCR-VL [6]	0.9B	85.54	92.11	85.97	82.54	89.61	77.47
	MinerU2.5 [3]	1.2B	85.61	90.06	83.76	89.41	89.57	75.24
	dots.ocr [34]	3B	86.38	86.87	86.01	87.18	87.57	84.27
	MinerU2.5-pro [16]	1.2B	88.96	92.11	88.72	91.29	91.42	81.26
	GLM-OCR [15]	-	90.32	92.67	90.68	91.75	91.12	85.39
	PaddleOCR-VL-1.5 [9]	0.9B	92.05	93.43	91.25	91.76	92.16	91.66
	PaddleOCR-VL-1.6	0.9B	93.19	94.74	92.48	92.78	93.28	92.66

表 3 | Real5-OmniDocBench 上的文档解析综合评估。

5.2. 核心子能力

本节针对PaddleOCR-VL-1.6在多个核心子能力方面的表现进行了详细评估，涵盖硬表格识别、图表解析、文本定位和印章识别。

5.2.1. 高难度表格识别

内部表格数据集。我们的内部评估数据集包含 1,258 个具有挑战性的表格样本，配有全面的标注和精细的类型标签。该数据集涵盖 20 类表格，包括中文、英文以及中英文混合表格，以及带有完整边框、部分边框或无边框的表格。该数据集还包含多种表格格式和场景，例如公式表、密集型表格、书籍和手册中的表格、列表、学术论文、合并单元格表格、低质量扫描件、带水印的表格、登记表、统计表、研究和财务报告、基于图像的表格、发票以及手写表格。

表 4 比较了在 In-house-Table 基准测试中不同方法的性能。PaddleOCR-VL-1.6 在总体 TEDS (91.71) 和结构化 TEDS (94.67) 两项指标上均取得最高分数，证明了其在具有挑战性的表格识别场景中的有效性和可靠性。

方法	总体 TEDS↑	结构化 TEDS↑
MonkeyOCR [2]	73.96	78.24
Qwen2.5-VL-3B [41]	73.98	77.65
dots.ocr [34]	75.47	79.14
Qwen2.5-VL-7B [41]	75.49	79.26
OCRFlux-3B [44]	77.41	80.71
Qwen2.5-VL-72B [41]	77.62	83.61
Nanonets-OCR-s [29]	78.24	81.90
MinerU2-VLM [43]	82.86	87.30
MinerU2.5 [3]	84.69	89.55
TRivia-3B [45]	86.12	91.16
GLM-OCR [15]	86.21	90.76
PaddleOCR-VL [6]	86.99	90.66
PaddleOCR-VL-1.5[9]	87.14	90.61
MinerU2.5-Pro[16]	89.77	93.78
PaddleOCR-VL-1.6	91.71	94.67

表 4 | 困难级表格识别基准测试的评估结果。

5.2.2. 图表解析

内部图表集。我们的内部图表识别评估集包含 1,801 个样本，所有样本均经过严格的人工审核，以确保标注的准确性。该数据集涵盖 11 种图表类别，包括条线混合图、饼图、100% 堆叠条形图、面积图、条形图、气泡图、直方图、折线图、散点图、堆叠面积图和堆叠条形图。其中包括 851 个英文样本和 950 个中文样本。在评估前，预测数据表和真实数据表均被规范化为统一的 Markdown 格式，以减少表达上的歧义。

如表5所示，PaddleOCR-VL-1.6在In-house-Chart基准测试中展现出最强的图表解析性能，其 RMS-F1[46]得分分别为：总体91.74、英文图表90.11、中文图表93.37。该模型表现优于其前代产品 PaddleOCR-VL 和 PP-StructureV3，凸显了其从复杂病历中提取结构化数据的强大能力。

模型	RMS-F1↑		
	总体	EN	ZH
TinyChart [47]	21.59	47.26	8.76
GOT [48]	31.60	11.00	41.90
OneChart [49]	37.16	13.84	48.82
qwenVL-2.5-72B [50]	73.00	69.72	74.64
HunyuanOCR [8]	75.13	65.54	79.92
PaddleOCR-VL-1.5 [9]	80.37	76.15	84.58
PP-StructureV3 [40]	80.60	79.63	81.09
PaddleOCR-VL [6]	84.40	82.22	85.49
Gemini 3 Flash [26]	89.45	88.23	90.66
PaddleOCR-VL-1.6	91.74	90.11	93.37

表 5 | 基于内部病历基准测试的病历解析性能对比。

5.2.3. 文本定位

In-house-Text-Spotting。该内部文本定位基准测试评估端到端 OCR 能力，涵盖文本检测与识别两个方面。测试涵盖 9 个具有代表性的维度，包括常见场景、日语文本、退化或低质量图像、中文和英文手写体、表格结构内容、古籍以及繁体中文。这些类别旨在反映多样化的文档场景和实际部署挑战，涵盖从常规印刷文本到布局敏感、低质量、手写以及历史风格的各类材料。

如表6所示，PaddleOCR-VL-1.6在所有9个评估维度上均实现了最高的定位准确率，并始终优于强大的基线模型。这些结果证明了该模型在各种视觉条件、文本样式和文档布局下的强大泛化能力，表明该模型无论在标准OCR场景中，还是在需要精确定位和忠实转录的具有挑战性的真实世界场景中，均能保持可靠性。

数据集	总体	古籍	模糊	常见	手写 ch	手写 en	印刷体 ch	打印 en	表格	日语
HunyuanOCR [8]	62.90	61.64	63.92	52.22	79.84	76.65	62.13	59.56	44.19	65.93
Rex-Omni [51]	66.82	42.51	69.36	61.12	81.47	78.12	69.61	60.88	71.85	66.42
PaddleOCR-VL-1.5 [9]	86.21	85.23	84.22	77.13	89.52	91.63	86.69	86.89	89.93	84.61
PaddleOCR-VL-1.6	87.47	85.98	90.59	77.28	85.90	92.60	91.26	86.51	92.32	84.76

表 6 | 在内部基准测试上的文本定位性能对比。“总体”指所有 9 个评估维度的平均准确率。

5.2.4. 印章识别

内部印章。内部印章识别基准测试旨在评估模型在专用印章文本识别方面的性能。该基准包含 300 张高质量图像，涵盖多种印章形状，包括圆形、椭圆形和矩形印章，以及文本重叠、低对比度印痕和背景失真等具有挑战性的真实场景。采用归一化编辑距离（NED）作为主要指标来衡量字符级识别准确率。

如表7所示，PaddleOCR-VL-1.6在印章识别方面展现出明显优势。尽管其参数规模仅为0.9B，但其NED值达到0.119，显著优于NED值为0.382的235B参数模型Qwen3-VL及其前代模型。这些结果凸显了该模型在处理专业文档元素方面的有效性。

模型	参数	NED (↓)
Qwen2.5-VL-72B [41]	72B	0.396
Qwen3-VL-235B-A22B-Instruct [25]	235B	0.382
PaddleOCR-VL-1.5 [9]	0.9B	0.138
PaddleOCR-VL-1.6	0.9B	0.119

表 7 | 基于内部印章基准的印章识别性能对比。

5.3. 消融研究

我们在 OmniDocBench v1.6 上进行了一项消融研究，以分析 PaddleOCR-VL-1.6 中各训练后阶段的贡献。从 PaddleOCR-VL-1.5 检查点开始，我们依次应用持续预训练（CPT）、监督微调（SFT）和强化学习（RL）。本次评估追踪了模型在若干代表性解析指标上的演变情况，包括总分、文本编辑距离、公式CDM、Table-TEDS以及Table-TEDS-S。

阶段	总体↑	文本 ^{编辑} ↓	公式 ^{CDM} ↑	表格 ^{TEDS} ↑	表格 ^{TEDS-S} ↑
PaddleOCR-VL-1.5 [9]	94.93	0.038	96.89	91.67	94.37
+ CPT	95.62	0.035	97.32	93.03	95.82
+ SFT	96.25	0.034	97.37	94.74	97.09
+ RL	96.33	0.033	97.49	94.76	97.11

表 8 | OmniDocBench v1.6 上渐进式训练后阶段的消融研究。

表 8 报告了 OmniDocBench v1.6 上各渐进式训练后阶段的贡献。从 PaddleOCR-VL-1.5 开始，完整的训练方案将总得分从 94.93% 提升至 96.33%，同时持续提升文本识别、公式识别和表格识别的各项指标。提升幅度最大的是 CPT 和 SFT 阶段。CPT 使总分提高了 0.69 个百分点，并将 Table-TEDS 从 91.67% 显著提升至 93.03%，这表明数据引擎提供的广泛分布扩展和校正监督为进一步优化奠定了坚实基础。SFT 阶段使总分再次提升了 0.63 分，并将 Table-TEDS 进一步提升至 94.74%，Table-TEDS-S 提升至 97.19%，这表明高质量的困难样本对于优化困难样本特别有效。

RL阶段带来的提升幅度虽小但依然积极，将总体得分从96.25%进一步提升至96.33%，并将Formula-CDM得分从97.37%提升至97.49%。这种相对温和的提升在预期之中，因为在OmniDocBench v1.6上经过CPT和SFT之后，模型已经达到了强劲的性能水平，留给进一步优化的空间有限。尽管如此，强化学习通过奖励引导式训练进一步优化了最终模型，助力实现了最佳的整体性能。这些结果表明，对于文档解析任务而言，主要的性能提升源于高质量的数据构建和分阶段的监督式适应，而强化学习则作为最终的优化步骤，将原本已表现强劲模型推向其性能上限。

6. 结论

本文提出 PaddleOCR-VL-1.6，这是一个基于 PaddleOCR-VL-1.5 构建的增强型紧凑文档解析模型，同时保留了其高效的 0.9B 架构。PaddleOCR-VL-1.6 并未依赖不加区分的模型扩展，而是通过基于未充分优化区域的数据引擎，以及涵盖 CPT、SFT 和

及强化学习（RL）的渐进式后训练管道，从而提升了性能。所得模型在OmniDocBench v1.6上实现了最先进水平，并在Real5-OmniDocBench上展现出强大的鲁棒性，同时在硬表格识别、图表解析、文本定位和印章识别等关键子能力上均取得了显著提升。这些结果表明，有针对性的数据优化和分阶段的后训练能够有效释放紧凑型文档大型语言模型（VLM）的剩余潜力。通过在多样化的真实世界场景中提供准确且稳健的文档理解能力，PaddleOCR-VL-1.6 为下游 RAG 系统、大型语言模型应用以及实用的文档智能 workflow 提供了高质量的解析基础。

参考文献

- [1] Patrick Lewis、Ethan Perez、Aleksandra Piktus、Fabio Petroni、Vladimir Karpukhin、Naman Goyal、Heinrich Küttler、Mike Lewis、Wen tau Yih、Tim Rocktäschel、Sebastian Riedel 和 Douwe Kiela。《面向知识密集型自然语言处理任务的检索增强生成》，2021 年。网址：<https://arxiv.org/abs/2005.11401>。
- [2] 张力、刘玉良、刘强、马志阴、张子阳、张硕、杨彪、郭子兀、张家瑞、王新宇和白翔。Monkeyocr：基于结构-识别-关系三元组范式的文档解析，2026。网址：<https://arxiv.org/abs/2506.05218>。
- [3] 牛俊波、刘正、顾壮成、王斌、欧阳林可、赵志远、楚涛、何天耀、吴凡、张钦通、金振江、梁广、张瑞、张文正、曲元、任志飞、孙月峰、郑元红、马东生、唐子瑞、牛博宇、苗子阳、董和军、钱思怡、张俊元、陈景州、王方东、赵晓萌、魏丽群、李伟、王莎莎、徐瑞亮、曹元元、陈璐、吴倩倩、顾怀宇、卢林东、王可明、林德臣、沈冠林、周玄和、张林峰，曾宇航、董晓怡、王佳琪、张博、白磊、楚佩、李伟佳、吴江、吴立军、李振祥、王广宇、涂中英、徐超、陈凯、乔宇、周博文、林大华、张文涛、何从辉。Mineru2.5：一种用于高效高分辨率文档解析的解耦视觉-语言模型，2025。网址：<https://arxiv.org/abs/2509.22186>。
- [4] 冯浩、魏舒、向飞、石伟、韩应东、廖磊、卢景辉、吴炳红、刘琪、林春辉、唐景群、刘浩和黄灿。Dolphin：基于异构锚点提示的文档图像解析，2025。网址：<https://arxiv.org/abs/2505.14059>。
- [5] 刘元、赵中音、田乐、王海成、叶旭兵、尤阳秀、于子林、吴楚汉、周晓、于阳和周杰。《Points-reader：用于文档转换的无蒸馏视觉语言模型适应》，2025。URL：<https://arxiv.org/abs/2509.01215>。
- [6] 崔成、孙婷、梁素音、高廷全、张泽伦、刘家轩、王雪清、周长达、刘宏恩、林曼慧、张悦、张宇博、郑汉东、张静、张军、刘毅、于电海和马廷军。Paddleocr-vl：通过 0.9b 超紧凑视觉语言模型增强多语言文档解析，2025。网址：<https://arxiv.org/abs/2510.14528>。
- [7] 魏浩然、孙耀峰和李玉坤。《Deepseek-ocr：基于上下文的光学压缩》，2025年。网址：<https://arxiv.org/abs/2510.18234>。

- [8] Hunyuan Vision团队、吕鹏元、万兴宇、李耿罗、彭尚品、王伟农、吴亮、沈华文、周宇、唐灿辉、杨琪、彭启明、罗斌、杨浩尔、张新松、张金年、彭后文、杨洪明、谢森浩、周龙沙、裴格、吴炳红、严瑞、吴坎、杨建能、王博超、刘凯、朱建臣、江杰、Linus、胡汉、张成全。《Hunyuanocr技术报告》，2025年。网址：<https://arxiv.org/abs/2511.19575>。
- [9] 崔成、孙婷、梁素音、高廷全、张泽伦、刘佳轩、王雪清、周长达、刘洪恩、林曼慧、张悦、张宇博、刘毅、于电海和马延军。PaddleOCR-VL-1.5：面向鲁棒真实场景文档解析的多任务0.9b VLM，2026年。网址：<https://arxiv.org/abs/2601.21957>。
- [10] 欧阳林克、曲元、周洪斌、朱家伟、张瑞、林群舒、王斌、赵志远、江曼、赵晓萌等。Omnidocbench：利用全面标注对多样化 PDF 文档解析进行基准测试。收录于《计算机视觉与模式识别会议论文集》，第24838–24848页，2025年。
- [11] 邵志红、王佩怡、朱琪浩、徐润新、宋俊晓、毕晓、张浩伟、张明川、李Y. K.、吴Y. 和郭大亚。《Deepseekmath：突破开放式语言模型中数学推理的极限》，2024年。URL <https://arxiv.org/abs/2402.03300>。
- [12] Mostafa Dehghani、Basil Mustafa、Josip Djolonga、Jonathan Heek、Matthias Minderer、Mathilde Caron、Andreas Steiner、Joan Puigcerver、Robert Geirhos、Ibrahim M Alabdulmohsin 等。Patch n’pack：Navit，一款适用于任何宽高比和分辨率的视觉变换器。《神经信息处理系统进展》，36:2252–2274，2023。
- [13] 百度-ERNIE团队。《Ernie 4.5技术报告》，2025年。
- [14] Daxiang Dong、Mingming Zheng、Dong Xu、Chunhua Luo、Bairong Zhuang、Yuxuan Li、Ruoyun He、Haoran Wang、Wenyu Zhang、Wenbo Wang、Yicheng Wang、Xue Xiong、Ayong Zheng、Xiaoying Zuo、Ziwei Ou、Jingnan Gu、Quanhao Guo、Jianmin Wu、Dawei Yin 和 Dou Shen。Qianfan-ocr：一种用于文档智能的统一端到端模型，2026年。网址 <https://arxiv.org/abs/2603.13398>。
- [15] 段帅琪、薛亚东、王卫涵、苏哲、刘欢、杨胜、甘国兵、王国、王子涵、严胜东、金德新、张玉轩、文国红、王彦峰、张宇涛、张晓涵、洪文怡、岑玉科、尹达、陈斌、于文萌、顾晓涛和唐杰。Glm-ocr技术报告，2026年。网址：<https://arxiv.org/abs/2603.10910>。
- [16] 王斌、何天耀、欧阳林可、吴凡、赵志远、楚涛、曲元、金振江、曾伟军、缪子阳、徐邦瑞等人。Mineru2.5-pro：突破大规模数据中心化文档解析的极限，2026。URL <https://arxiv.org/abs/2604.04771>。
- [17] 王海峰、吴华、吴天、孙宇、刘静、于电海、马艳军、何景洲、何中军、董红等。《Ernie 5.0技术报告》。arXiv 预印本 arXiv:2602.04705，2026年。网址 <https://arxiv.org/abs/2602.04705>。
- [18] 崔成、孙婷、梁素音、高廷全、张泽伦、刘家轩、王雪清、周长达、刘洪恩、林曼辉等。Paddleocr-vl-1.5：面向鲁棒真实场景文档解析的多任务 0.9 b VLM。arXiv 预印本 arXiv:2601.21957，2026年。网址 <https://arxiv.org/abs/2601.21957>。

- [19] 于琪颖、张正、朱若飞、袁玉峰、左晓晨、岳宇、戴维南、范天天、刘高红、刘凌军等。Dapo：一个大规模的开源大语言模型强化学习系统。《神经信息处理系统进展》，38:113222–113244，2026。网址 <https://arxiv.org/abs/2503.14476>。
- [20] 周长达、高子月、王雪清、高廷全、崔成、唐静和刘毅。《Real5-omnidocbench：用于真实环境中鲁棒文档解析的全规模物理重建基准》，2026年。网址 <https://arxiv.org/abs/2603.04205>。
- [21] 王斌、吴凡、欧阳林可、顾壮成、张瑞、夏仁秋、石博天、张博和何从辉。《图像覆盖文本：利用字符检测匹配革新公式识别评估》。收录于《IEEE/CVF计算机视觉与模式识别会议（CVPR）论文集》，第19681–19690页，2025年6月。
- [22] 王伟云、高张伟、顾丽新、浦恒军、崔龙、魏兴光、刘兆阳、景玲林、叶胜龙、邵杰等。《Internvl3.5：提升开源多模态模型在通用性、推理能力和效率方面的表现》。arXiv预印本 arXiv:2508.18265，2025年。网址 <https://arxiv.org/abs/2508.18265>。
- [23] Kimi团队、白彤彤、白一凡、鲍一平、S. H. 蔡、曹元、Y. Charles、H. S. Che 等。Kimi k2.5：视觉代理智能，2026年。网址 <https://arxiv.org/abs/2602.02276>。
- [24] OpenAI. GPT-5.2 系统简介，2025年。网址 https://cdn.openai.com/pdf/3a4153c8-c748-4b71-8e31-aecbde944f8d/oai_5_2_system-card.pdf。
- [25] 杨安、李安峰、杨宝松、张北辰、许斌元、郑波、于博文、高畅、黄成根、吕陈旭等人。《Qwen3 技术报告》。arXiv 预印本 arXiv:2505.09388，2025年。网址 <https://arxiv.org/abs/2505.09388>。
- [26] Google DeepMind. Gemini 3.0. <https://blog.google/products-and-platforms/products/gemini/gemini-3-collection/>，2025年。
- [27] 卢世银、李阳、陈清国、徐兆、罗伟华、张凯富和叶汉佳。《Ovis：面向多模态大型语言模型的结构化嵌入对齐》，2024年。网址 <https://arxiv.org/abs/2405.20797>。
- [28] 卢诗音、杨莉、于霞、胡宇威、赵珊珊、马艳清、魏志超、李英伦、段伦浩、赵建山、韩玉轩、李海军、陈万英、唐俊科、侯成坤、杜志兴、周天利、张文杰、丁虎平、李佳和、李文、胡贵、顾一良、杨思然、王佳芒、孙海龙、王一博、孙慧、黄金龙、何玉平、石胜泽、张伟红、郑国东、蒋军鹏、高森森、吴一峰、陈思佳、陈玉辉、陈庆国、徐兆、罗伟华和张开复。《Ovis2.5技术报告》，2025年。网址：<https://arxiv.org/abs/2508.11737>。
- [29] Souvik Mandal、Ashish Talewar、Paras Ahuja 和 Prathamesh Juvatkar。《Nanonets-ocr-s：一种通过智能内容识别和语义标注将文档转换为结构化 Markdown 的模型》，2025年。
- [30] Mistral AI 团队。Mistral-ocr。 https://mistral.ai/news/mistral-ocr?utm_source=ai-bot.cn，2025年。

- [31] 杰克·波兹南斯基、乔恩·博查特、杰森·邓克尔伯格、雷根·霍夫、丹尼尔·林、阿曼·兰加普尔、克里斯托弗·威廉、凯尔·罗和卢卡·索尔达伊尼。olmocr：利用视觉语言模型解锁PDF中的数万亿个令牌。arXiv预印本 arXiv:2502.18443，2025年。网址 <https://arxiv.org/abs/2502.18443>。
- [32] 钟宇峰、陈磊、赵玄乐、韩文康、郑丽明、黄静、姜德阳、曹一林、马林和曾志雄。Ocrverse：面向端到端视觉语言模型中的整体OCR，2026年。网址 <https://arxiv.org/abs/2601.21639>。
- [33] 杜永坤、陈智能、谢亚珍、白伟康、冯浩、石伟、苏玉晨、黄灿和姜宇刚。Unirec-0.1b：基于0.1b参数的统一文本与公式识别，2025。网址 <https://arxiv.org/abs/2512.21095>。
- [34] 李玉萌、杨广、刘浩、王博文和张科林。dots.ocr：基于单一视觉语言模型的多语言文档布局解析，2025年。网址 <https://arxiv.org/abs/2512.02498>。
- [35] 小红书公司超级智能团队。《Firedred-ocr技术报告》，2026年。网址 <https://arxiv.org/abs/2603.01840>。
- [36] 辛安、蔡静怡、陈向阳、刘华瑶、刘培婷、王鹏、杨贝、朱秀文、陈永凡、高燕等。《Logics-parsing-omni 技术报告》。arXiv预印本 arXiv:2603.09677，2026年。网址 <https://arxiv.org/abs/2603.09677>。
- [37] 尹坤、吴云飞、刘冰、蔡中鹏、李晓天、陈黄、李鑫、曹浩宇、刘银松、江德强、孙兴、吴云生、李倩宇、郭安泰、廖艳珍、曲艳秋、林浩东、何成旭和刘双音。Youtu-parsing：通过高并行度解码实现感知、结构化与识别，2026。网址 <https://arxiv.org/abs/2601.20430>。
- [38] OpenDataLab. Omnidocbench 1.6. <https://opendatalab.com/omnidocbench>, 2026.
- [39] Vik Paruchuri. Marker. <https://github.com/datalab-to/marker>, 2025. 访问日期：2025-09-25.
- [40] 崔成、孙婷、林曼辉、高廷全、张宇博、刘家轩、王雪清、张泽伦、周长达、刘洪恩等。PaddleOCR 3.0 技术报告。arXiv预印本 arXiv:2507.05595，2025年。网址 <https://arxiv.org/abs/2507.05595>。
- [41] 白帅、陈可勤、刘雪静、王家林、葛文斌、宋思博、当凯、王鹏、王世杰、唐军等。《Qwen2.5-vl 技术报告》。arXiv预印本 arXiv:2502.13923，2025年。网址 <https://arxiv.org/abs/2502.13923>。
- [42] Google DeepMind. Gemini 2.5. <https://blog.google/technology/google-deepmind/gemini-model-thinking-updates-march-2025/>，2025年。
- [43] OpenDataLab. Mineru2.0-2505-0.9b. <https://huggingface.co/opendatalab/MinerU2.0-2505-0.9B>, 2025.
- [44] chatdoc-com. Ocrflux. <https://github.com/chatdoc-com/OCRFlux>, 2024年。访问日期：2025年5月28日。
- [45] 张俊元、王斌、张钦通、吴凡、温子辰、卢家林、山俊杰、赵子琪、杨舒雅、王子玲、苗子阳、钟华平、曾宇航、董晓怡、周嘉豪和何从辉。《趣闻：用于餐桌识别的视觉语言模型的自监督微调》，2026年。网址：<https://arxiv.org/abs/2512.01248>。

- [46] 刘方宇、朱利安·马丁·艾森施洛斯、弗朗切斯科·皮奇诺、西琳·克里切内、庞陈曦、肯顿·李、曼达尔·乔希、陈文虎、奈杰尔·科利尔和亚塞明·阿尔图恩。《Deplot：基于情节到表格转换的一次性视觉语言推理》，2023年。网址 <https://arxiv.org/abs/2212.10505>。
- [47] 张亮、胡安文、徐海阳、严明、徐一晨、金秦、张吉和黄飞。Tinychart：基于视觉令牌合并与思维程序学习的高效图表理解。arXiv 预印本 arXiv:2404.16635，2024。网址 <https://arxiv.org/abs/2404.16635>。
- [48] 魏浩然、刘成龙、陈金月、王佳、孔凌宇、徐延明、葛正、赵亮、孙建建、彭元、韩春瑞和张向宇。《通用OCR理论：通过统一的端到端模型迈向OCR 2.0》，2024年。URL <https://arxiv.org/abs/2409.01704>。
- [49] 陈金月、孔凌宇、魏浩然、刘成龙、葛正、赵亮、孙建建、韩春瑞和张向宇。《OneChart：通过一个辅助令牌净化图表结构提取》。收录于《第32届ACM国际多媒体会议论文集》，第147–155页，2024年。
- [50] 白帅、陈可琴、刘雪静、王家林、葛文斌、宋思博、当凯、王鹏、王世杰、唐军、钟虎门、朱元志、杨明坤、李兆海、万建强、王鹏飞、丁伟、傅哲仁、徐一恒、叶佳博、张曦、谢天宝、程泽森、张航、杨志博、徐海阳和林俊阳。《Qwen2.5-vl技术报告》，2025年。网址 <https://arxiv.org/abs/2502.13923>。
- [51] 江青、霍俊安、陈兴宇、熊宇达、曾昭阳、陈一浩、任天河、于俊志和张磊。通过下一帧预测检测任何物体。arXiv 预印本 arXiv:2510.12798，2025年。网址 <https://arxiv.org/abs/2510.12798>。